FIAP — FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA
CURSO SUPERIOR DE TECNOLOGIA EM INTELIGÊNCIA ARTIFICIAL

BRUNO LANCHARICHE FITIPALDI LOPES
GUSTAVO CIVITA GONÇALVES
RAFAEL DE PAIVA RAMOS
THIAGO SANTANA DANYLUK
ARTHUR PEDRECA DE ALMEIDA VASCO
GRUPO 4M — TURMA 2TIPAY

OBSERVABILIDADE DO ENDPOINT DE SENSORES DA PLATAFORMA FORZY:

contrato de métricas, limiares e plano de resposta para a Sensor Monitoring API

Documento técnico-acadêmico apresentado às disciplinas de Governança em Inteligência Artificial e de Front-end do Curso Superior de Tecnologia em Inteligência Artificial da FIAP, como requisito de avaliação do checkpoint integrado "Observabilidade de um endpoint de IA — Sensor Monitoring API". Complementa a documentação do Challenge Sprint do projeto Forzy · Digital Twin.

SÃO PAULO
2026

RESUMO

Este documento define e valida o contrato de observabilidade do endpoint de sensores da solução Forzy · Digital Twin, no checkpoint integrado de Governança em IA e Front-end. O provider de Sensores foi exposto em uma API FastAPI e consumido por uma interface Streamlit que envia, em toda chamada, os headers X-Session-Id e X-Feature; um middleware registra cada requisição com a latência, o código de resposta e a qualidade do dado devolvido. Sobre esses registros foram definidos oito indicadores, cada um com limiares, baseline, gráfico recomendado e plano de resposta. A validação com 5.357 chamadas coletadas em 54 minutos mostrou que quatro dos oito indicadores cumpriram o contrato; os desvios foram rastreados até o gateway de um ativo e até um cliente sem instrumentação. A análise revelou ainda um atraso de cerca de dois segundos percebido apenas no front, invisível aos indicadores medidos no servidor.

Palavras-chave: observabilidade; governança de inteligência artificial; freshness; indicadores de nível de serviço; FastAPI.

SUMÁRIO

1 INTRODUÇÃO 3

2 ENDPOINT E CONTRATO DE OBSERVABILIDADE 3

3 INDICADORES, LIMIARES E BASELINES.....4

4 CAMADA GRÁFICA POR INDICADOR 5

5 PLANO DE RESPOSTA A LIMIARES ESTOURADOS.....6

6 VALIDAÇÃO COM OS REGISTROS COLETADOS 7

7 USO DE INTELIGÊNCIA ARTIFICIAL 9

8 CONCLUSÃO.....10

REFERÊNCIAS.....10

1 INTRODUÇÃO

O projeto Forzy · Digital Twin monitora motores elétricos industriais por meio da telemetria de sensores. Nas sprints anteriores, a governança cobriu o ativo e o acesso (Sprint 1), a visualização (Sprint 2) e a decisão, com o contrato de métrica e o *circuit breaker* (Sprint 3). Este checkpoint governa o próprio serviço: registrar, em cada chamada ao endpoint de sensores, quem chamou, quando, a partir de qual funcionalidade e quanto tempo a operação levou, para que o comportamento do sistema possa ser auditado.

O objetivo é definir um contrato mínimo de observabilidade para esse endpoint — indicadores, limiares, baselines, camada gráfica e plano de resposta — e validá-lo com os registros efetivamente coletados pelo back-end. O escopo é apenas o provider de Sensores (leitura atual e histórico), sem autenticação e com **dados fictícios** gerados de forma determinística.

2 ENDPOINT E CONTRATO DE OBSERVABILIDADE

A Sensor Monitoring API, em FastAPI, expõe quatro rotas sob o prefixo `/v1`: catálogo de ativos, leitura atual e histórico de cada TAG e relatório de observabilidade, consumidas pela interface Streamlit via requests. Um middleware intercepta toda requisição, mede a latência, lê os headers de contexto, gera um identificador único e grava o registro em SQLite (Figura 1). O provider simula cinco ativos com falhas típicas da cadeia de aquisição: o gateway do MOT-005 é intermitente, o do BMB-002 oscila e os demais são estáveis.

O contrato **FORZY-OBS-SENSORES** (versão 1.0.0) define o que cada chamada carrega e o que o back-end registra:

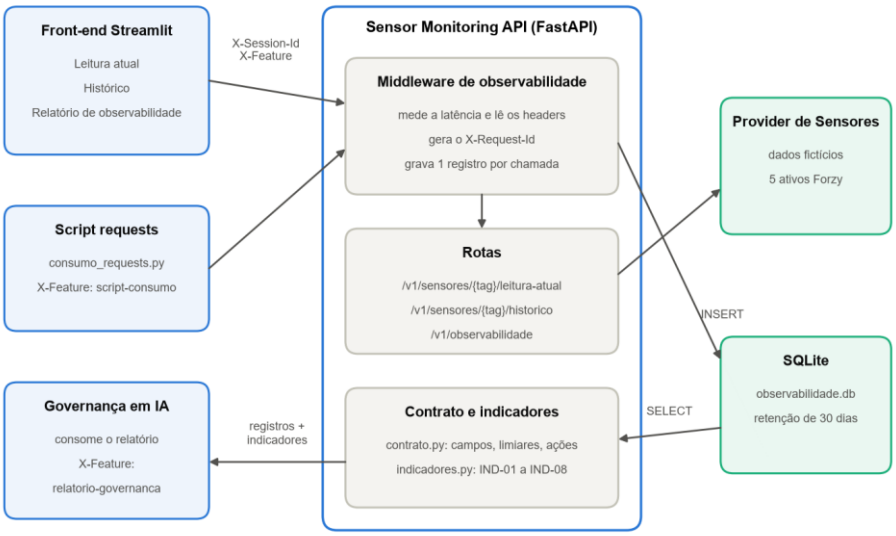
a) **headers de contexto obrigatórios**: `X-Session-Id`, um UUID gerado por aba do navegador, e `X-Feature`, a funcionalidade da interface que originou a chamada;

b) **campos registrados**: identificador, instante UTC, rota, TAG, sessão, funcionalidade, cliente (User-Agent), código de resposta, latência no servidor, idade do dado, severidade e completude do histórico, nomeados

de forma equivalente às convenções do OpenTelemetry (OPENTELEMETRY, 2026);

c) **registro não bloqueante**: a chamada sem headers é atendida, mas fica registrada como contexto incompleto e recebe o header de resposta `X-Observabilidade-Aviso`;
d) **rastreabilidade**: o `X-Request-Id` devolvido ao cliente liga o que o usuário viu ao registro do back-end;
e) **minimização e retenção**: não são guardados o IP do cliente nem o corpo das requisições, e os registros são mantidos por 30 dias;
f) **versionamento**: toda mudança de campo, limiar ou ação gera uma nova versão do contrato.

Figura 1 – Arquitetura da Sensor Monitoring API e fluxo dos registros de observabilidade



Fonte: elaborado pelos autores (2026).

3 INDICADORES, LIMIARES E BASELINES

Os oito indicadores do Quadro 1 respondem a quatro perguntas: o serviço responde a tempo (IND-01, IND-02 e IND-06)? O dado entregue é atual e completo (IND-03, IND-04 e IND-07)? Cada chamada é rastreável (IND-05)? A saída do classificador se comporta como esperado (IND-08)? Seguindo Beyer *et al.* (2016), latência e idade do dado usam o percentil 95, e não a média, que esconderia a cauda lenta.

Quadro 1 – Indicadores e limiares do contrato de observabilidade

Código	Indicador e fórmula	Meta (OK)	Atenção	Crítico
IND-01	**Latência p95 — leitura atual** p95 da latência nas leituras atuais com status < 500	≤ 250 ms	250 a 800 ms	> 800 ms
IND-02	**Latência p95 — histórico** p95 da latência nos históricos com status < 500	≤ 600 ms	600 a 1.500 ms	> 1.500 ms
IND-03	**Tempo de atualização** p95 da idade do dado nas leituras atuais com status 200	≤ 15 s	15 a 60 s	> 60 s
IND-04	**Taxa de completude de freshness** % das leituras atuais com idade ≤ 15 s	≥ 95%	90% a 95%	< 90%
IND-05	**Completude dos metadados de contexto** % das chamadas com X-Session-Id e X-Feature	≥ 99%	95% a 99%	< 95%
IND-06	**Taxa de erro do servidor** % das chamadas com status ≥ 500	≤ 1%	1% a 5%	> 5%
IND-07	**Completude do histórico** % médio de pontos recebidos ÷ esperados	≥ 98%	95% a 98%	< 95%
IND-08	**Proporção de leituras críticas** % das leituras atuais com severidade crítica	≤ 25%	25% a 40%	> 40%

Fonte: elaborado pelos autores (2026), com base em Nielsen (1993), Beyer *et al.* (2016) e Grupo 4M (2026).

Os limiares vêm de requisitos do usuário e da operação, e não da baseline, para que um serviço degradado não redefina o que é aceitável. A latência respeita o limite de cerca de 1 s de Nielsen (1993) para não interromper o raciocínio do usuário, e o SLA de 15 s para a idade do dado equivale a três períodos de publicação, a mesma regra que trava a decisão no *circuit breaker* da Sprint 3 (GRUPO 4M, 2026). A **baseline** de cada indicador é a mediana dos valores em janelas de 5 minutos, medida sobre 5.357 chamadas de 50 sessões coletadas em 08/10/2026, durante 54 minutos; janelas com menos de 20 chamadas foram descartadas. Os valores medidos estão no Quadro 4.

4 CAMADA GRÁFICA POR INDICADOR

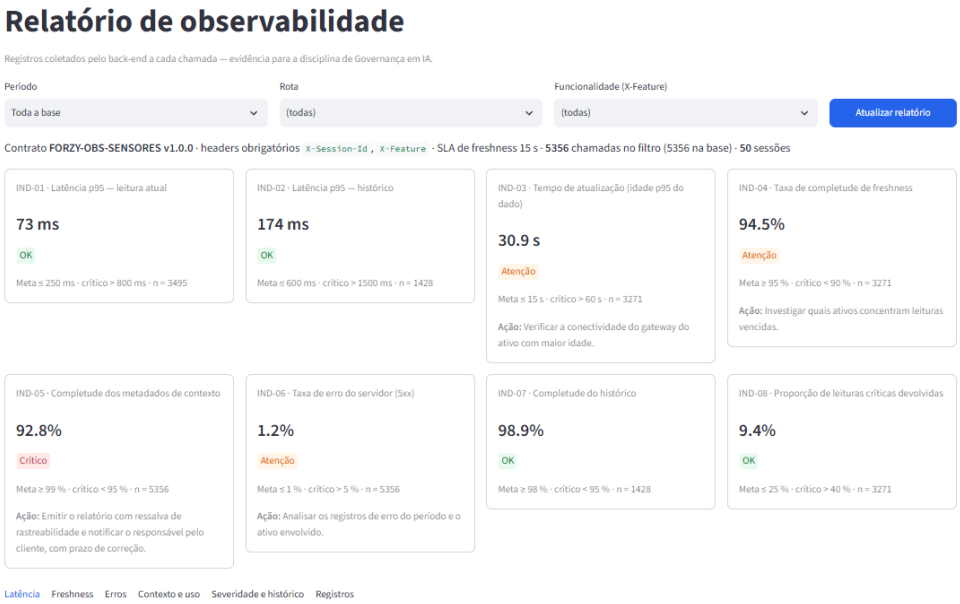
Cada gráfico foi escolhido pela pergunta que o indicador responde (Quadro 2): linha para a evolução no tempo, *box plot* para a distribuição, pequenos múltiplos para comparar ativos na mesma escala (TUFTE, 1990) e barras para comparar categorias. Em todos, os limiares são desenhados no próprio gráfico, para que o estouro seja percebido de relance (FEW, 2013). Os gráficos ficam disponíveis, de forma interativa, na tela de observabilidade da interface (Figura 2).

Quadro 2 – Camada gráfica recomendada para cada indicador

Código	Gráfico recomendado
IND-01	Linha temporal do p95 em janelas de 5 min, com linhas de limiar
IND-02	Linha temporal do p95 em janelas de 5 min + box plot da distribuição por rota
IND-03	Pequenos múltiplos por ativo da idade p95 em janelas de 5 min, com linha do SLA de 15 s
IND-04	Linha temporal da taxa em janelas de 5 min, com linhas de meta (95%) e crítico (90%)
IND-05	Cartão de KPI com meta + barras horizontais por cliente (User-Agent)
IND-06	Linha temporal da taxa de 5xx em janelas de 5 min + barras empilhadas de status por rota
IND-07	Barras por ativo com linha de meta de 98%
IND-08	Barras empilhadas 100% de severidade por ativo

Fonte: elaborado pelos autores (2026).

Figura 2 – Relatório de observabilidade na interface, com os indicadores do contrato



Fonte: captura de tela da aplicação desenvolvida (2026).

5 PLANO DE RESPOSTA A LIMIARES ESTOURADOS

O status de cada indicador é recalculado a cada janela de 5 minutos. **Atenção** abre chamado após duas janelas seguidas fora da meta, para evitar alarme por oscilação pontual; **crítico** aciona a resposta já na primeira janela; o incidente é encerrado após três janelas em OK. Se o nível crítico não for assumido no prazo, a resposta é escalonada ao Gestor de Planta, como no handoff humano da Sprint 3. Os responsáveis são os perfis do RBAC do projeto (Quadro 3).

Quadro 3 – Plano de resposta por indicador e nível

Código	Ao atingir atenção	Ao atingir crítico	Responsável (prazo atenção / crítico)
IND-01	Abrir chamado de desempenho e verificar a latência do gateway de borda.	Acionar o plantão de TI; o painel passa a exibir aviso de lentidão ao operador.	Administrador do Sistema 4 h / 15 min
IND-02	Revisar o tamanho das janelas consultadas e o índice do historiador.	Limitar a janela máxima do histórico até a causa ser corrigida.	Administrador do Sistema 4 h / 15 min
IND-03	Verificar a conectividade do gateway do ativo com maior idade.	Marcar o ativo como “dado vencido” no painel e acionar a manutenção de campo.	Engenheiro de Manutenção 4 h / 15 min
IND-04	Investigar quais ativos concentram leituras vencidas.	Suspender decisões automáticas baseadas na leitura atual até a taxa voltar a 95%.	Engenheiro de Manutenção (Técnico de Operação informado) 4 h / 15 min
IND-05	Identificar pelo User-Agent o cliente que não envia os headers.	Emitir o relatório com ressalva de rastreabilidade e notificar o responsável pelo cliente, com prazo de correção.	Auditor de Segurança 1 dia útil / 4 h
IND-06	Analisar os registros de erro do período e o ativo envolvido.	Abrir incidente e comunicar a indisponibilidade aos usuários do painel.	Administrador do Sistema 4 h / 15 min
IND-07	Sinalizar as lacunas no gráfico do histórico para o analista.	Não usar o período como base de tendência; reprocessar a série no historiador.	Engenheiro de Manutenção e Cientista de Dados 1 dia útil / 4 h
IND-08	Comparar com a baseline: confirmar se é piora real dos ativos ou desvio do classificador.	Encaminhar ao Engenheiro de Manutenção para validação humana antes de novas ações.	Cientista de Dados e Engenheiro de Manutenção 1 dia útil / 4 h

Fonte: elaborado pelos autores (2026).

6 VALIDAÇÃO COM OS REGISTROS COLETADOS

O Quadro 4 confronta a baseline, o valor no período inteiro e a pior janela de 5 minutos de cada indicador. **Quatro dos oito indicadores cumpriram o contrato**; IND-03, IND-04, IND-05 e IND-06 ficaram fora da meta.

Quadro 4 – Resultado da validação do contrato no período de coleta

Código	Indicador	Baseline	Valor no período	Status	Pior janela
IND-01	Latência p95 — leitura atual	72 ms	73 ms	OK	523 ms às 15:05
IND-02	Latência p95 — histórico	170 ms	174 ms	OK	844 ms às 14:45
IND-03	Tempo de atualização (idade p95 do dado)	7,8 s	30,9 s	Atenção	74,8 s às 14:55
IND-04	Taxa de completude de freshness	97,6%	94,5%	Atenção	79,3% às 14:55
IND-05	Completude dos metadados de contexto	100,0%	92,8%	Crítico	75,0% às 15:30
IND-06	Taxa de erro do servidor (5xx)	0,0%	1,3%	Atenção	6,3% às 15:25
IND-07	Completude do histórico	98,9%	98,9%	OK	98,5% às 14:55
IND-08	Proporção de leituras críticas devolvidas	7,0%	9,4%	OK	19,5% às 15:15

Fonte: elaborado pelos autores a partir dos registros coletados pela API (2026).

Os principais achados foram:

a) **atualidade do dado**: MOT-005 teve 79,3% das leituras dentro do SLA de 15 s, com idade máxima de 90 s, e BMB-002, 95,4%; os demais ativos ficaram em 100% (Figura 3);

b) **erros do servidor**: as 67 respostas 5xx vieram todas da leitura atual do MOT-005, durante as quedas do seu gateway; a taxa global foi de 1,3%, mas a pior janela chegou a 6,3% (Figura 4);

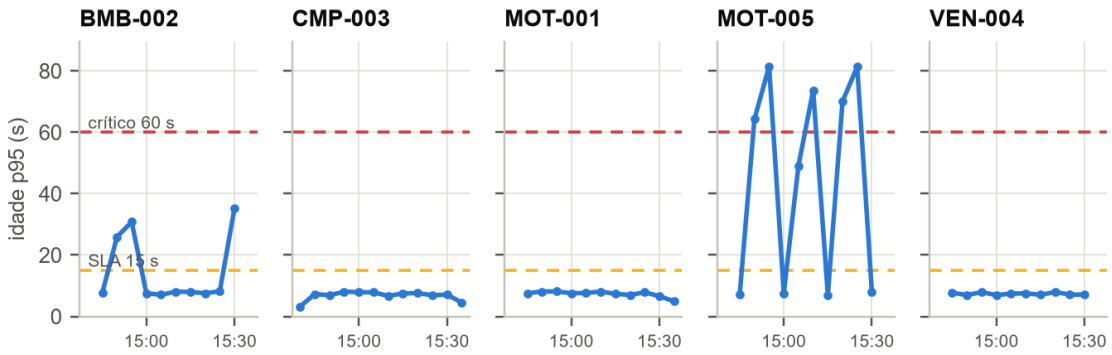
c) **rastreabilidade**: IND-05 ficou em nível crítico (92,8%) por causa de um cliente legado sem os headers (383 chamadas), identificado pelo User-Agent (Figura 5); pelo plano de resposta, o relatório é emitido **com ressalva de rastreabilidade**;

d) **completude do histórico**: 98,9% no geral, dentro da meta, mas 97,6% no MOT-005, que isoladamente ficaria em atenção;

e) **latência e severidade**: a latência ficou dentro da meta nas duas rotas; a hipótese de que o relatório de observabilidade deixava a API lenta foi descartada pelos registros, e a severidade devolvida é coerente com os perfis simulados;

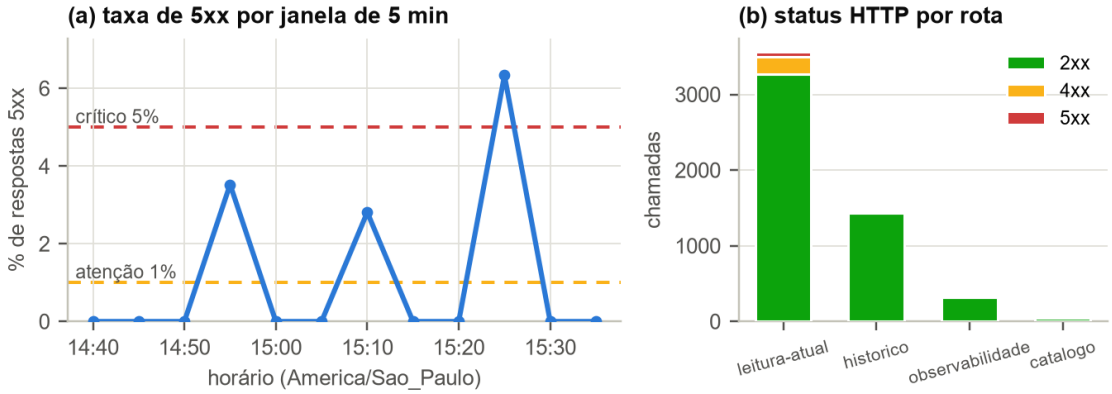
f) **latência percebida no front**: uma leitura levou 46 ms no servidor e 2.106 ms no front, porque `localhost`, no Windows, tenta o IPv6 antes do IPv4; com `127.0.0.1` e o reaproveitamento da conexão, o tempo caiu para 81 ms. Os indicadores do servidor não detectaram esse atraso.

Figura 3 – Idade p95 do dado por ativo em janelas de 5 minutos (pequenos múltiplos)



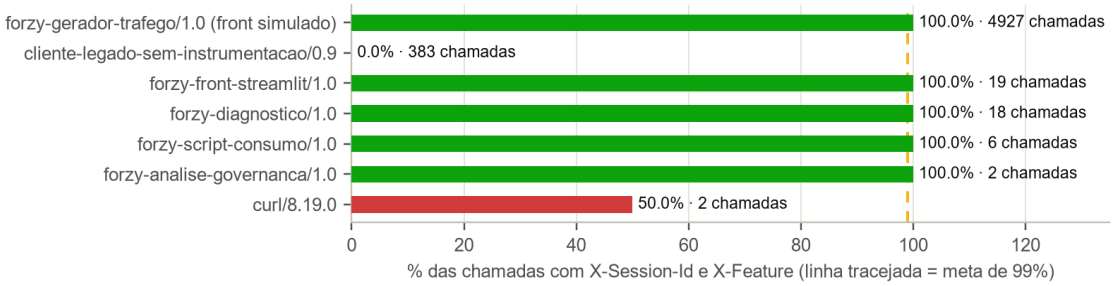
Fonte: elaborado pelos autores a partir dos registros coletados pela API (2026).

Figura 4 – Erros: (a) taxa de respostas 5xx por janela; (b) status HTTP por rota



Fonte: elaborado pelos autores a partir dos registros coletados pela API (2026).

Figura 5 – Completude dos metadados de contexto por cliente



Fonte: elaborado pelos autores a partir dos registros coletados pela API (2026).

Limitações. Além das discutidas na conclusão, a API roda em instância única, e por isso a saturação não é medida. Os registros completos, em CSV, acompanham a entrega na pasta `evidencias/`.

7 USO DE INTELIGÊNCIA ARTIFICIAL

O grupo usou o assistente Claude, da Anthropic, para estruturar o código da API, do middleware e da interface, construir o provider fictício e o gerador de carga,

gerar os gráficos, redigir e condensar as seções descritivas e redigir a conclusão (seção 8). Todos os números foram calculados a partir dos registros efetivamente coletados pela API, e nenhum dado pessoal foi enviado à ferramenta. O grupo responde integralmente pela entrega.

8 CONCLUSÃO

O principal aprendizado deste checkpoint é que um indicador agregado pode mostrar um problema, mas os registros de chamadas revelam onde ele está. Apesar de 67 erros 5xx resultarem em uma taxa de 1,3%, a análise por rota mostrou que todos vieram do MOT-005, com uma taxa de 6,3% em um determinado horário. Um achado importante foi que a leitura atual estava dentro da meta, mas a interface apresentava um tempo de resposta muito maior. Isso destaca a importância de medir a latência percebida. A emissão de um relatório com ressalva de rastreabilidade é preferível a bloqueios, e os limiares precisam ser recalibrados com dados reais. O método usado transformou perguntas vagas em questões claras respondidas pelos registros.

REFERÊNCIAS

BEYER, Betsy; JONES, Chris; PETOFF, Jennifer; MURPHY, Niall Richard (org.). **Site reliability engineering**: how Google runs production systems. Sebastopol: O'Reilly Media, 2016.

FEW, Stephen. **Information dashboard design**: displaying data for at-a-glance monitoring. 2. ed. Burlingame: Analytics Press, 2013.

GRUPO 4M. **Inteligência operacional e governança da decisão na plataforma Forzy**: contrato de métrica, limites de autonomia algorítmica e supervisão humana no Digital Twin de motores elétricos industriais. 2026. Documento técnico-acadêmico (Challenge Sprint 3) — FIAP, São Paulo, 2026.

NIELSEN, Jakob. **Usability engineering**. San Francisco: Morgan Kaufmann, 1993.

OPENTELEMETRY. **Semantic conventions for HTTP**. [*S. l.*], 2026. Disponível em: https://opentelemetry.io/docs/specs/semconv/http/. Acesso em: 8 out. 2026.

TUFTE, Edward R. **Envisioning information**. Cheshire: Graphics Press, 1990.